

Modelos de Sobrevivência com fragilidade Birnbaum-Saunders

Guilherme Braga Pinto

Vinícius Paiva de Araujo

1. INTRODUÇÃO

Modelos de sobrevivência com inclusão de componente de fragilidade servem para modelar casos em que dados não são capazes de explicar totalmente um determinado evento de interesse dado Modelos de Cox tradicionais. Nesse contexto, a fragilidade é interpretada como um efeito aleatório não observado que influencia o tempo até a ocorrência do evento e que, embora não seja diretamente mensurável, possui influência reconhecida sobre o fenômeno em estudo. É um caso comum para aplicações médicas em que se tenta explicar fatores genéticos aleatórios ou outros fatores de ambiente do indivíduo, como exemplificado em Colosimo e Giolo (2024).

Como a “fragilidade” do indivíduo em estudo não é observada diretamente, esta classe de modelos deve assumir uma distribuição de probabilidade para o termo que compõe a fragilidade em si. Apesar de distribuições tradicionais tenham sido testadas como a uniforme, a weibull e a log-normal (VAUPEL; YASHIN, 1983), as propriedades analíticas das distribuições gama e da gaussiana generalizada as tornam alternativas populares. Entende-se que a análise da variância do termo de fragilidade permite quantificar a heterogeneidade não mensurada pelo conjunto de dados em estudo, dado que a esperança deste componente deve ser definida e limitada para que seja possível satisfazer a propriedade de identificabilidade dos parâmetros do modelo.

Esforços recentes introduzem a distribuição Birnbaum-Saunders como uma alternativa para este termo, especialmente por se tratar de uma distribuição assimétrica, positiva e contínua à direta com propriedades analíticas desejáveis para o problema proposto por modelos de fragilidade. Originalmente essa distribuição foi modelada para descrever o processo de fadiga em materiais da indústria aeronáutica como mostrado em Birnbaum e Saunders (1969). Consequentemente, é amplamente utilizada em aplicações de confiabilidade para modelar tempos até a falha além de ter sido aplicada para problemas do domínio de financeiro ao modelar tempo de duração de operações em bolsa de valores com visto em Mayorov (2011).

Os resultados apresentados por Leão et al. (2018), por meio de uma parametrização alternativa da distribuição Birnbaum-Saunders, evidenciam seu potencial para utilização em modelos de fragilidade, tanto sob o ponto de vista teórico quanto aplicado.

Desta forma, os objetivos deste trabalho são:

- Apresentar os fundamentos teóricos dos modelos de fragilidade em análise de sobrevivência;
- Estudar as propriedades da distribuição Birnbaum-Saunders em sua versão reparametrizada e sua aplicação como distribuição de fragilidade;
- Explorar a distribuição Birnbaum-Saunders Reparametrizada e distribuição alternativa clássica para modelos de fragilidade, a Gama Generalizada.

- Aplicar modelos de fragilidade a dados reais, reproduzindo os resultados apresentados em Leão et al. (2018), dando ênfase ao conjunto de dados descrito por Kalbfleisch e Prentice (2002).

2. METODOLOGIA

2.1 Modelos de Fragilidade

Considere o Modelo de Cox com variável aleatória não observável U e tempo de interesse de evento T . Define-se a função de risco condicional como:

$$h_{T|U=u_i}(t; \theta_1, \theta_2) = u_i h_0(t; \theta_1), \quad i = 1, \dots, n, t > 0.$$

Em que u_i é o componente de fragilidade de um indivíduo i , h_0 é a função de risco basal e que θ_1 e θ_2 são parâmetros de tempo de vida e fragilidade. Se $u_i > 1$, maior o risco aleatório dado por componente de fragilidade, e se $u_i < 1$, menor este risco.

Consequentemente é possível definir a função de sobrevivência condicional também desta forma:

$$S_{T|U=u_i}(t; \theta_1, \theta_2) = \exp \{-u_i H_0(t; \theta_1)\}, \quad i = 1, \dots, n, t > 0.$$

Levando em conta censura à direita, se obtém que:

$$t_i = \min\{y_i, c_i\},$$

em que

$$k_i = I(y_i \leq c_i)$$

é um indicador de censura, sendo 1 para evento de interesse e 0 para censura.

Dada a formulação de função de verossimilhança comportando censuras à direita dado vetor de parâmetros $\theta = (\theta_1, \theta_2)^\top$:

$$\begin{aligned} L(\theta) &= \prod_{i=1}^n [f(t_i; \theta)]^{k_i} [S(t_i; \theta)]^{1-k_i} \\ &= \prod_{i=1}^n [h(t_i; \theta)]^{k_i} S(t_i; \theta), \end{aligned}$$

é possível obter a função de log-verossimilhança da seguinte forma:

$$\ell(\theta; \mathbf{t}, \boldsymbol{\kappa}, \mathbf{u}) = \sum_{i=1}^n k_i \log(u_i h_0(t_i)) - \sum_{i=1}^n u_i H_0(t_i),$$

Em que se tem um vetor de fragilidades $\mathbf{u}$, um vetor de eventos $\mathbf{t}$ e um vetor de indicadores de censura $\boldsymbol{\kappa}$.

Posteriormente pode-se obter função que não dependa de fragilidade a marginalizando, ou seja, tirando a dependência em u_i por integração:

$$L_i(\theta) = \int_0^\infty [f_{T|U}(t_i | u_i; \theta)]^{k_i} [S_{T|U}(t_i | u_i; \theta)]^{1-k_i} g_U(u_i; \theta_2) du_i$$

sendo $g(u)$ a densidade de probabilidade da variável aleatória de fragilidade U . Como, em dados com censura à direita,

$$f_T(t_i; \theta) = h_T(t_i; \theta)S_T(t_i; \theta),$$

se tem que:

$$L_i(\theta) = [h_T(t_i; \theta)S_T(t_i; \theta)]^{\kappa_i} [S_T(t_i; \theta)]^{1-\kappa_i}.$$

Logo, para n indivíduos aplicando logaritmo na função de verossimilhança:

$$\ell(\theta; \mathbf{t}, \boldsymbol{\kappa}) = \sum_{i=1}^n \kappa_i \log(h_T(t_i; \theta)) + \sum_{i=1}^n \log(S_T(t_i; \theta)).$$

Assim $h_T(t; \theta)$ e $S_T(t; \theta)$ não estão condicionadas em U . Como o componente de fragilidade U é uma variável aleatória, para se obter $S_T(t; \theta)$, chega-se naturalmente à definição da transformada de Laplace (CASELLA; BERGER, 2002) de U (já que a formulação envolve tomar a esperança em relação à distribuição U). Conforme exposto em Leão et al. (2018), distribuições para U que tenham transformada de Laplace definidas são fortes candidatas para serem a distribuição a ser utilizada para fragilidade.

Modelos de fragilidade são frequentemente formulados como extensões dos modelos de riscos proporcionais, introduzindo uma variável aleatória não observada U que atua multiplicativamente sobre a função de risco. Assim, condicionalmente a U , assume-se uma estrutura de riscos proporcionais. Entretanto, após integrar a distribuição da fragilidade, a função de risco marginal resultante não necessariamente preserva a propriedade de proporcionalidade dos riscos (WIENKE; ANDREAS, 2010).

Assumindo-se uma distribuição paramétrica para a taxa de risco basal $h_0(t; \theta_1)$, além de uma distribuição para a própria variável aleatória de fragilidade U , obtém-se uma expressão analítica para a função de verossimilhança. Assim, é possível obter estimativas para os parâmetros de interesse por meio de métodos numéricos tradicionais implementados em linguagem R.

Conforme exemplificado em Colosimo e Giolo (2024), também é possível trabalhar com uma abordagem semiparamétrica de fragilidade, em que a taxa de risco basal é assumida arbitrária e uma outra distribuição é assumida para o componente de fragilidade. Em seu exemplo, considera-se a distribuição gama, cujos parâmetros são estimados por meio da maximização da função de verossimilhança parcial penalizada. Neste trabalho se dá ênfase para abordagens em que são assumidas distribuições definidas para $h_0(t; \theta_1)$, como feito originalmente em Leão et al. (2018).

2.2 Distribuição Birnbaum-Saunders

Uma variável aleatória X possui distribuição Birnbaum-Saunders caso ela possa ser representada pela transformação de uma variável aleatória com distribuição normal padrão, $Z \sim N(0, 1)$, dado que:

$$X = \sigma \left[\frac{kZ}{2} + \left(\left(\frac{kZ}{2} \right)^2 + 1 \right)^{1/2} \right]^2$$

em que $k > 0$ e $\sigma > 0$ e estes são parâmetros de forma e escala, respectivamente.

Para este caso, é usada a notação de $X \sim BS(k, \theta)$ e sua função de probabilidade é obtida por:

$$f(x; k, \sigma) = \frac{1}{\sqrt{2\pi}} \exp \left(-\frac{1}{2k^2} \left[\frac{x}{\sigma} + \frac{\sigma}{x} - 2 \right] \right) \frac{x^{-3/2}(x + \sigma)}{2k\sigma^{1/2}}, \quad x > 0.$$

Pode-se mostrar que $E[X] = \sigma[1 + \frac{k^2}{2}]$; $Var[X] = [k\sigma]^2[1 + \frac{5k^2}{4}]$; com a mediana da distribuição sendo o parâmetro de escala σ . A função de sobrevivência e função de risco de X podem ser expressas por:

$$S(x; \kappa, \sigma) = \Phi \left(-\frac{1}{\kappa} \left[\sqrt{\frac{x}{\sigma}} - \sqrt{\frac{\sigma}{x}} \right] \right),$$

$$h(x; \kappa, \sigma) = \frac{\phi \left(\frac{1}{\kappa} \left[\sqrt{\frac{x}{\sigma}} - \sqrt{\frac{\sigma}{x}} \right] \right) x^{-3/2}(x + \sigma)}{2\kappa\sigma^{1/2}\Phi \left(-\frac{1}{\kappa} \left[\sqrt{\frac{x}{\sigma}} - \sqrt{\frac{\sigma}{x}} \right] \right)}, \quad x > 0,$$

em que ϕ e Φ são a função de distribuição de uma normal padrão e sua função de distribuição acumulada, respectivamente.

2.3 Estimação de Parâmetros para Birnbaum-Saunders Reparametrizada

O trabalho de Leão et al. (2018) introduz uma reparametrização da distribuição Birnbaum-Saunders como uma proposta à distribuição Gama tradicionalmente utilizada para componente de fragilidade.

A distribuição RBS é indexada pelos parâmetros:

$$\mu = \beta \left(1 + \frac{\alpha^2}{2} \right) \quad \text{e} \quad \delta = \frac{2}{\alpha^2},$$

em que $\alpha > 0$ e $\beta > 0$ são os parâmetros originais da distribuição Birnbaum-Saunders, conforme Birnbaum e Saunders (1969). Além disso, $\mu > 0$ representa um parâmetro de escala e coincide com a média da distribuição, enquanto $\delta > 0$ representa um parâmetro de forma e precisão. A notação

$$U \sim RBS(\mu, \delta)$$

indica que a variável aleatória U segue uma distribuição Birnbaum–Saunders reparametrizada com parâmetros μ e δ .

Dada a Birnbaum–Saunders original, é possível se obter a forma de sua reparametrização. A densidade de variável aleatória $U \sim RBS(\mu, \delta)$ é dada por:

$$f_U(u; \mu, \delta) = \frac{\exp(\delta/2)\sqrt{\delta+1}}{4u^{3/2}\sqrt{\pi\mu}} \left(u + \frac{\delta\mu}{\delta+1}\right) \exp\left\{-\frac{\delta}{4} \left[\frac{u(\delta+1)}{\delta\mu} + \frac{\delta\mu}{u(\delta+1)}\right]\right\}, \quad u > 0.$$

Sua função de sobrevivência e de taxa de falha é dada respectivamente por:

$$S_U(u; \mu, \delta) = \frac{1}{2}\Phi\left(\frac{u + \delta(u - \mu)}{2\sqrt{u(1 + \delta)\mu}}\right), \quad u > 0.$$

$$h_U(u; \mu, \delta) = \frac{\exp\left\{-\frac{(-\delta\mu + \delta u + u)^2}{4(\delta+1)\mu u}\right\}(\delta\mu + \delta u + u)}{(\pi\mu(\delta+1))^{1/2} 2\mu^{1/2} u^{3/2} \Phi\left(\frac{u + \delta(u - \mu)}{2\sqrt{u(1 + \delta)\mu}}\right)}, \quad u > 0.$$

As Figuras 1 e 2 demonstram o comportamento respectivamente das funções de taxa de falha e da função densidade da distribuição Birnbaum–Saunders reparametrizada, em que se impõe a restrição $E[U] = 1$, garantindo a identificabilidade do modelo de fragilidade proposto.

Figura 1 – Função de taxa de falha da distribuição Birnbaum-Saunders Reparametrizada (BSR)





Figura 2 – Função de densidade da distribuição Birnbaum-Saunders Reparametrizada



Algumas razões adicionais podem ser destacadas para justificar o uso da distribuição RBS:

1. sua parametrização baseada na média permite analisar os dados em sua escala original;
2. a distribuição RBS apresenta-se como uma alternativa bastante competitiva para o ajuste de modelos de fragilidade;
3. a distribuição RBS já foi utilizada antes para análise de dados médicos (Desmond, 1985);
4. a distribuição RBS possui transformada de Laplace explícita;
5. a distribuição RBS permite modelar dados bimodais. É uma distribuição assimétrica, positiva, contínua à direita (importante, por multiplicar risco basal no modelo de Fragilidade).

2.4 Resíduos Quantílicos e de Cox-Snell

A análise de resíduos é uma etapa primordial na seleção de modelos em um estudo estatístico. Para este trabalho, foram utilizados, principalmente, os resíduos quantílicos e de Cox-Snell para avaliação de modelos.

A forma como são obtidos os resíduos quantílicos é ao transformar a função de distribuição acumulada da variável resposta em uma variável com distribuição normal-padrão por

meio da função inversa da distribuição normal. Ou seja, quando o modelo está bem comportado, espera-se que esses resíduos sejam aproximadamente independentes e que sigam uma distribuição normal. Portanto, os resíduos quantílicos são definidos por:

$$r_i = \Phi^{-1}(F(y_i; \hat{\theta})), \quad i = 1, 2, \dots, n,$$

em que $F(y_i; \hat{\theta})$ representa a função de distribuição acumulada da variável resposta avaliada na observação y_i , considerando os parâmetros estimados $\hat{\theta}$, e Φ^{-1} denota a função quantil da distribuição normal padrão, ou seja, a inversa da função de distribuição acumulada.

Quanto aos resíduos de Cox-Snell, estes são obtidos ao aplicar uma transformação na função de sobrevivência de cada observação. Caso o modelo adequado para os dados, espera-se que essa transformação siga uma distribuição exponencial com média igual a 1. Então, os resíduos de Cox-Snell são definidos por:

$$r_i = -\log(S(y_i; \hat{\theta})), \quad i = 1, 2, \dots, n,$$

em que $S(y_i; \hat{\theta})$ representa a função de sobrevivência avaliada na observação y_i . Quando expressos pela função de distribuição acumulada F , eles podem ser escritos como:

$$r_i = -\log(1 - F(y_i; \hat{\theta})).$$

2.5 Comparação Visual com curva de Kaplan–Meier

Para uma análise visual da curva da função de sobrevivência dos modelos ajustados, utiliza-se a curva de Kaplan Meier como um *baseline*. Segundo Kaplan e Meier (1958), a curva de sobrevivência pode ser estimada de forma em que não existe a necessidade de se assumir uma distribuição para os tempos até o evento de interesse.

A função de sobrevivência estimada pelo método de Kaplan–Meier é:

$$\hat{S}(t) = \prod_{t_i \leq t} \left(1 - \frac{d_i}{n_i}\right) = \prod_{t_i \leq t} \frac{n_i - d_i}{n_i},$$

em que:

- t_i é o i -ésimo tempo distinto em que ocorre um evento;
- d_i é o número de eventos observados no tempo t_i ;
- n_i é o número de indivíduos sob risco imediatamente antes de t_i .

2.6 Análise de resultados

Para avaliar a adequação do modelo a ser ajustado, serão utilizados diferentes tipos de abordagens, conforme descrito por Colosimo e Giolo (2024) e aplicados originalmente por Leão et al. (2018):

- **Critérios de Informação:** Os critérios de informação mais utilizados em estudos estatísticos são os de Akaike (AIC) e Bayesiano (BIC). Eles são utilizados para comparar modelos diferentes para o mesmo banco de dados, em que o modelo que apresenta menor valor de AIC e/ou BIC indica que ele seja o melhor modelo candidato.
- **Gráfico TTT:** O gráfico de Tempo Total de Teste (TTT) é utilizado para analisar como é o comportamento do modelo proposto em relação com a função de risco dos dados. Caso os pontos estejam próximo à linha de 45° , isso é um indício que possuem uma distribuição com função de risco constante.
- **Análise de Resíduos:** A análise de resíduos é essencial para verificar se o modelo proposto é minimamente adequado para os dados. Uma forma de fazer essa análise é por meio dos resíduos padronizados vs valores ajustados, em que é esperado que seja percebido um comportamento aleatório e sem tendência, o que indica não-heterocedasticidade.
- **Análise visual de curva de Sobrevida:** Análise feita ao se observar o comportamento da curva de Kaplan-Meier. Dependendo do seu comportamento, é possível observar indícios que violem suposições de, por exemplo, riscos proporcionais. Além disso, essa análise ajuda em comparar curvas de grupos diferentes, podendo ser observado, por exemplo, qual grupo possui curva de sobrevida maior.

Em adição aos modelos de fragilidade implementados, também utiliza-se os dados para analisar a adequação de abordagens clássicas paramétricas com e sem o uso de covariáveis disponibilizadas.

3 RESULTADOS

Os resultados analisados neste trabalho estão disponíveis no repositório de Braga e Paiva (2026), em que os códigos utilizados na aplicação foram implementados em linguagem R.

3.1 Conjunto de Dados

Os dados utilizados na aplicação a seguir foram obtidos de um conjunto de dados apresentado por Kalbfleisch e Prentice (2002), referente ao tempo de sobrevivência, em meses, de pacientes diagnosticados com câncer.

Tabela 1 – Primeiras observações do conjunto de dados

Obs.	Variáveis observadas							
	trt	celltype	time	status	karno	diagtime	age	prior
1	1	squamous	72	1	60	7	69	0
2	1	squamous	411	1	70	5	64	10
3	1	squamous	228	1	60	3	38	0
4	1	squamous	126	1	60	9	63	10
5	1	squamous	118	1	70	11	65	10
6	1	squamous	10	1	20	5	49	0

A Tabela 1 apresenta as primeiras observações do conjunto de dados *veteran*. O conjunto contém informações de pacientes com câncer de pulmão, incluindo o tratamento recebido, o tipo celular do tumor, o tempo de sobrevivência observado, o indicador de status do evento, a pontuação de desempenho de Karnofsky, o tempo desde o diagnóstico, a idade do paciente e a realização prévia de terapia.

3.3 Especificação do Modelo de Fragilidade Ajustado

Os resultados obtidos podem ser analisados por meio das Tabelas 2 e 3 para componentes de fragilidade seguindo a Birnbaum–Saunders reparametrizada e a distribuição Gama respectivamente.

Todos os parâmetros dos modelos foram estimados pelo método da máxima verossimilhança. Para isso, utilizou-se a função `optim` do software R, responsável pela otimização numérica da função de log-verossimilhança negativa. Todos os códigos utilizados nesta etapa da análise para obtenção de parâmetros foram reproduzidos e disponibilizados pelos autores conforme trabalho de Leão et al. (2018).

Tabela 2 – Resultados dos ajustes dos modelos com componente de fragilidade seguindo a distribuição Birnbaum–Saunders reparametrizada.

Risco basal	Parâmetro	Estimativa	Erro-padrão	Estatística z	p-valor
<i>Modelo com risco basal exponencial</i>					
Exponencial	δ	0,953912	0,191074	4,992380	$5,9641 \times 10^{-7}$ ***
Exponencial	λ	0,020228	0,003763	5,375340	$7,6438 \times 10^{-8}$ ***
<i>Modelo com risco basal Weibull</i>					
Weibull	α	68,389681	42,100441	1,624440	0,104282
Weibull	η	1,191970	0,407547	2,924740	0,003447 **
Weibull	δ	1,625480	2,936078	0,553620	0,579837

Medida	Exponencial	Weibull
Variância estimada da fragilidade	1,809386	1,196980
Log-verossimilhança	−755,1879	−746,8145
AIC	1514,376	1499,629
BIC	1520,216	1508,389

Nota: *** $p < 0,001$; ** $p < 0,01$.

Tabela 3 – Resultados dos ajustes dos modelos com componente de fragilidade seguindo a distribuição Gama.

Risco basal	Parâmetro	Estimativa	Erro-padrão	Estatística z	p-valor
<i>Modelo com risco basal exponencial</i>					
Exponencial	σ^2	1,683662	6,064521	0,277620	0,781300
Exponencial	λ	0,017752	0,023434	0,757530	0,448730
<i>Modelo com risco basal Weibull</i>					
Weibull	σ^2	2,490918	0,802409	3,104300	0,001907 **
Weibull	α	30,266235	5,706706	5,303630	$1,1352 \times 10^{-7}$ ***
Weibull	η	1,677248	0,280291	5,983940	$2,1780 \times 10^{-9}$ ***

Medida	Exponencial	Weibull
Log-verossimilhança	−766,8381	−763,1084
AIC	1537,676	1532,217
BIC	1543,516	1540,977

Nota: *** $p < 0,001$; ** $p < 0,01$.


Diante desses dados, o modelo com fragilidade Birnbaum–Saunders reparametrizada e risco basal Weibull apresentou o melhor ajuste por conta de se obter os menores valores para AIC e BIC, além de maior log-verossimilhança. Portanto, segundo esses critérios, esse modelo deve ser preferido em relação às demais especificações de fragilidade consideradas.

3.4 Análise do Modelo e dos Resíduos

Como o modelo com fragilidade Birnbaum–Saunders apresentou os menores valores de AIC e BIC, agora será analisado como os seus resíduos se comportam em relação a outros


modelos e também como o seu gráfico de tempo total em teste (TTT) se adequa. A Figura 3 revela que a proporção acumulada de falhas está abaixo da linha tracejada, o que indica que a taxa de falha é crescente. Ou seja, já é possível descartar a distribuição Exponencial como um candidato bom para o conjunto de dados de interesse.

Figura 3 – Gráfico TTT para conjunto de dados analisados.




A Figura 4 mostra como ficaram os resíduos de Cox-Snell para as distribuições RBS e Gama com risco basal exponencial e Weibull. Como é possível ver, nenhum dos modelos ficou obteve comportamento de resíduos dentro de uma margem boa, sendo que o que obteve melhor desempenho foi o modelo com fragilidade Gama e risco basal Weibull, porém este ainda assim não foi satisfatório. Isso indica que o ajuste global do modelo não ficou muito bom, com provável influência do número de censuras e/ou problemas quanto ao peso das caudas. Entretanto, como é possível na figura a seguir, o comportamento dos resíduos quantílicos foi bastante superior.

Figura 4 – Análise dos resíduos de Cox–Snell para os modelos com componente de fragilidade seguindo as distribuições Birnbaum–Saunders reparametrizada e Gama. Na linha superior, apresentam-se os modelos com fragilidade Birnbaum–Saunders reparametrizada; na linha inferior, os modelos com fragilidade Gama. Em ambas as linhas, o risco basal exponencial é apresentado à esquerda e o risco basal Weibull à direita.



A Figura 5 mostra como ficaram os resíduos quantílicos para as distribuições RBS e Gama com risco basal exponencial e Weibull. Fica explícito que, comparado ao concorrentes, a distribuição BSR com risco basal exponencial (gráfico superior à esquerda) foi o que obteve melhor comportamento dos seus resíduos.

Figura 5 – Análise dos resíduos quantílicos para os modelos com componente de fragilidade seguindo as distribuições Birnbaum–Saunders reparametrizada e Gama. Na linha superior, apresentam-se os modelos com fragilidade Birnbaum–Saunders reparametrizada; na linha inferior, os modelos com fragilidade Gama. Em ambas as linhas, o risco basal exponencial é apresentado à esquerda e o risco basal Weibull à direita.



3.5 Comparação com Modelos Paramétricos Tradicionais

Um conjunto de modelos paramétricos tradicionais foram testados paralelamente para se entender a performance da construção de um modelo com componente de fragilidade para este conjunto de dados específico, inicialmente sem se considerar covariáveis disponibilizadas no conjunto de dados original. A Tabela 4 demonstra os critérios de informação para cada ajuste testado, indicando que modelos paramétricos sem componente de fragilidade também podem ser considerados para este caso específico. Os modelos paramétricos tradicionais seguindo weibull e exponencial tradicionais apresentaram os menores AIC e BIC nesta análise, mesmo levando em conta modelos com componente de fragilidade.

Tabela 4 – Comparação dos modelos paramétricos sem covariáveis segundo os critérios de informação AIC e BIC.


Distribuição	Número de parâmetros	AIC	BIC
Exponencial	1	1478,993	1481,906
Weibull	2	1477,127	1482,952
Log-normal	2	1482,608	1488,433
Log-logística	2	1484,202	1490,028
Logística	2	1603,054	1608,879
Gaussiana	2	1637,215	1643,040

Nota: Os menores valores de cada critério estão destacados em negrito.

Uma forma tradicional de se avaliar modelos paramétricos, como demonstrado por Colosimo e Giolo (2024), é dada por meio de métodos visuais. Apesar de existir uma margem de erro na interpretação por parte do responsável pela análise (o que atribui subjetividade ao processo), esses métodos são considerados de grande valor por complementar testes clássicos como os critérios de informação e o teste de razão de verossimilhanças (TRV).

A comparação visual da curva de sobrevivência de Kaplan–Meier com nossos modelos paramétricos de maior interesse é dada por meio da Figura 6.

Figura 6 – Curva de função de Sobrevivência para modelos Weibull e Exponencial, comparando com modelo tradicional de Kaplan–Meier.



Conforme realizado para modelos com componente de fragilidade, a análise de resíduos também foi gerada para os modelos paramétricos com melhores valores de AIC e BIC. O resultados foram consolidados nas Figuras 7 e 8.

Figura 7 – Análise dos resíduos de Cox–Snell para os modelos paramétricos tradicionais.





Figura 8 – Análise dos resíduos de QQ–plot dos resíduos quantílicos para os modelos paramétricos tradicionais.



O resultado indica ajuste satisfatório dos modelos paramétricos seguindo distribuição exponencial e distribuição weibull.

A inclusão de covariáveis para os modelos paramétricos demonstram consistentemente melhorar a performance e a análise de resíduos, porém se mostra necessário analisar quais variáveis são estatisticamente significativas para a melhora do ajuste dos modelos testados.

Uma análise de seleção de variáveis por método *stepwise* foi realizada, considerando os critérios de informação AIC e BIC. Entende-se que a pontuação de desempenho de Karnofsky e o tipo celular do tumor são as covariáveis mais relevantes para explicar a sobrevida dos indivíduos presentes no conjunto de dados com base nos resultados da análise. Os códigos e resultados complementares dessa análise estão disponíveis no repositório de Braga e Paiva (2026).

CONCLUSÃO

O modelo de fragilidade Birnbaum–Saunders apresentou desempenho superior ao modelo clássico com fragilidade Gama. Entretanto, os modelos paramétricos tradicionais forneceram fortes indícios de melhor ajuste aos dados. A decisão de qual modelo deve ser utilizado deve, se possível, ser tomada em conjunto com um especialista da área de aplicação, considerando o conhecimento sobre o evento analisado em si. A fragilidade introduz uma variável aleatória que representa fatores de risco não medidos, permitindo que indivíduos com as mesmas covariáveis observadas ainda apresentem riscos diferentes. Nos modelos paramétricos tradicionais, essa heterogeneidade individual não observada não é representada explicitamente.

No escopo de modelos em que se deseja levar em conta a heterogeneidade não observada entre indivíduos, a distribuição Birnbaum–Saunders Reparametrizada se mostra uma alternativa forte em relação à abordagem tradicional em que se modela o componente de fragilidade por meio de uma distribuição Gama.

REFERÊNCIAS

- COLOSIMO, E. A.; GIOLO, S. R. *Análise de sobrevivência aplicada*. São Paulo: Edgard Blücher, 2006.
- BIRNBAUM, Z. W.; SAUNDERS, S. C. *A new family of life distributions*. Journal of Applied Probability, v. 6, n. 2, p. 319-327, 1969.
- CASELLA, George; BERGER, Roger L. *Statistical inference*. 2. ed. Pacific Grove: Duxbury, 2002.
- MAYOROV, K. *Modelling trade durations with the Birnbaum-Saunders autoregressive model*. Master's thesis, McMaster University, 2011.
- LEÃO, Jeremias; LEIVA, Víctor; SAULO, Helton; TOMAZELLA, Vera. *A survival model with Birnbaum–Saunders frailty for uncensored and censored cancer data*. Brazilian Journal of Probability and Statistics, v. 32, n. 4, p. 707–729, 2018. DOI: 10.1214/17-BJPS360.
- VAUPEL, J. W.; YASHIN, A. I. *The deviant dynamics of death in heterogeneous populations*. Laxenburg: International Institute for Applied Systems Analysis, 1983. Research Report RR-83-1.
- WIENKE, Andreas. *Frailty Models in Survival Analysis*. Boca Raton: Chapman and Hall/CRC, 2010.
- DESMOND, A. *Stochastic models of failure in random environments*. Canadian Journal of Statistics, v. 13, p. 171-183, 1985.
- KAPLAN, Edward L.; MEIER, Paul. *Nonparametric estimation from incomplete observations*. Journal of the American Statistical Association, v. 53, n. 282, p. 457–481, 1958. DOI: 10.1080/01621459.1958.10501452.
- BRAGA, Guilherme; PAIVA, Vinícius. *trabalho_final_analise_de_sobrevivencia*. GitHub, 2026. Disponível em: <https://github.com/gui1080/trabalho_final_analise_de_sobrevivencia>. Acesso em: 12 jul. 2026.